

1. Introduction and Problem Statement

探討的問題

如何在實數或複數點集上，高效、靈活且穩健地計算有理函數逼近，於給定實數或複數點集上的函數 $f(z)$ ，使其結果為一個有理函數 $r(z)$

問題的重要性

1. 提供 Compact Representations of Function：當函數 on or near the domain of approximation，或者在 unbounded domains 有極點或其他奇異點時，有理函數比多項式更有效率。
2. Extrapolation：提取函數在已知範圍之外的極點、數值或其他性質，例如序列和級數收斂加速的標準方法 (eta and epsilon algorithms) 就是基於有理函數逼近，有理逼近是解決解析延拓 (analytic continuation) 問題最有效的方法。

AAA 演算法的重要性

在有理逼近領域提供了高效、靈活性和穩健性，是作者在其他演算法中沒見過的，包含：

1. 性能優勢：在圓盤或區間上，AAA 演算法也可能贏過現有其他方法。
2. 領域靈活性：AAA 演算法的特點是不受特定逼近域 (interval, a circle, a disk, or a point) 的限制，能有效處理可能包含非連通區域、形狀不規則或 possibly unbounded 的離散點集。
3. 極點處理能力：被逼近的函數即使極點位於採樣點集之中，AAA 演算法也能有效運作。

2. Method Explanation

重心有理表示法 (Barycentric Rational Representation)

AAA 演算法的基礎是重心公式，其形式如下：

$$r(z) = \frac{n(z)}{d(z)} = \sum_{j=1}^m \frac{w_j f_j}{z - z_j} \Bigg/ \sum_{j=1}^m \frac{w_j}{z - z_j},$$

m 是逼近的階數， z_j 是支援點 (support points)， f_j 是函數值(data values)， w_j 是權重(weights)，如果權重 w_j 不為零，則 $r(z)$ 是一個 $(m - 1, m - 1)$ 的有理插值函數，滿足 $r(z_j) = f_j$ 的插值條件。

重心表示法的關鍵在於數值品質 (numerical quality)，這種表示法由 $1/(z - z_j)$ 項的商組成，選擇良好的 z_j 可以使表示法具有足夠的獨立性，使得條件數良好 (well-conditioned)，在許多情況下比 $p(z)/q(z)$ 的多項式商表示法，或向量擬合 (vector fitting) 使用的部分分式表示法條件數更優。

貪婪選擇支援點 (Adaptive Greedy Selection)

演算法以迭代方式逐步逼近，在每一步都貪婪地選擇最佳支援點，避免指數級的不穩定性

1. 初始化：演算法從一個有限的採樣點集 Z 開始。
2. 貪婪選擇支援點 (Greedy Selection)：在第 m 步，新的支援點 z_m 會從未被選為支援點的剩餘採樣點集 $Z^{(m-1)}$ 中選出，依據該點能使上一步的非線性殘差 $|f(z) - n(z)/d(z)|$ 達到最大絕對值。
3. 建立線性化最小平方法問題 (Linearized Least-Squares)：

原始目標是最小化 $f(z) \approx \frac{n(z)}{d(z)}$ 在採樣點集上的誤差，將此非線性問題線性化為 $f(z)d(z) \approx n(z)$ ，目標是求解權重 $w = (w_1, \dots, w_m)^T$ ，使其在排除支援點 z_j 的剩餘點集 $Z^{(m)}$ 上，最小化 $|fd - n|_{Z^{(m)}}$ (殘差的離散二範數)，同時滿足權重向量的正規化條件 $\|w\|_m = 1$

4. 矩陣形式 (Loewner 矩陣)：上述最小化問題被轉化為一個線性代數問題：

$\min \|A^{(m)}w\|_{M-m}$ 。其中 $A^{(m)}$ 是一個Loewner 矩陣，元素結構為 $\frac{F_i^{(m)} - f_j}{Z_i^{(m)} - z_j}$ ，而且可以用 Cauchy 矩陣 C 構建，表達為 $A^{(m)} = S_F C - CS_f$

5. 奇異值分解求解 (SVD Solution)：通過計算 $A^{(m)}$ 矩陣的奇異值分解 (SVD)，權重向量 w 被設定為與最小奇異值對應的最終右奇異向量。
6. 迭代與終止：演算法持續進行，在非線性殘差降至預設容忍度 (10^{-13}) 以下終止，線性化殘差的範數 $\sigma_{min}(A^{(m)})$ 是不遞增的函數。

3. Simple Implementation / Experiment

實驗設定與步驟

假設要逼近的函數是 $f(z) = 1/(z + 2)$ ，在 $z = -2$ 有極點的有理函數。

- 採樣點和函數值的定義 (M, Z, F)

在複數平面上定義 $M = 10$ 個採樣點，假設在 $[-1, 1]$ 區間的實數上取 10 個點 $z_1 \sim z_{10}$ 。

- 選擇支援點 (m, z, f)

選擇 $m = 3$ 個點作為支援點 z_j ，對應的函數值 f_j ，建立一個為 $(m - 1, m - 1) = (2, 2)$ 的有理逼近式。

- 定義剩餘點集 $(Z^{(m)}, F^{(m)}, J)$

AAA 演算法通過在非支援點集 $Z^{(m)}$ 上最小化線性殘差來求解權重 w 。

$Z^{(m)}$ ：從 Z 中移除 z 後剩餘 $M - m = 7$ 的個點

$F^{(m)}$ ：函數在 $Z^{(m)}$ 上的值

J ：用於索引 $|Z^{(m)}|$ 點的索引集

- 構建用於 SVD 求解的 Loewner 矩陣 $A^{(m)}$

AAA 演算法的目標是最小化線性化殘差 $\min \|fd - n\|_{Z^{(m)}}$

轉化為矩陣問題： $\min \|A^{(m)}w\|_{M-m}$

i. 構建 Cauchy 矩陣 C ：一個 $(M - m) * m$ 矩陣，元素定義了 AAA 逼近使用的部分分式基底 $1/(z - z_j)$ 。

$$C_{i,j} = \frac{1}{Z_i^{(m)} - z_j}$$

ii. 縮放矩陣 S_F 和 S_f ：

S_F 是 $(M - m) * (M - m)$ 對角矩陣，對角線元素為 $F^{(m)}$ 的值。

S_f 是 $m * m$ 對角矩陣，對角線元素為 f (支援點的函數值) 的值。

iii. 構建 Loewner 矩陣 $A^{(m)}$ ： $A^{(m)} = S_F C - CS_f$

$$A_{i,j}^{(m)} = \frac{F_i^{(m)} - f_j}{Z_i^{(m)} - z_j}$$

- 求權重向量 w

AAA 演算法通過對 $A^{(m)}$ 進行奇異值分解 (SVD) 來求解權重 w

$$A^{(m)} = U\Sigma V^*$$

權重向量 w 為對應最小奇異值的最終右奇異向量 $V(:, m)$ ，同時滿足 $\|w\|_m = 1$ 的正規化條件。

6. 計算有理函數 $r(z)$ 的分子 $n(z)$ 和分母 $d(z)$ ，當權重 w 被確定，可以在非支援點 $Z^{(m)}$ 上計算分子和分母的值 N 和 $D : N = C \cdot (w \odot f), D = C \cdot w$
 $(w \odot f)$ 為元素級的乘積，有理逼近結果 R 在這些點上就是 $R(Z^{(m)}) = N/D$

4. Summary or conclusion

AAA 演算法的核心優勢在於速度、靈活性和穩健性，通過結合兩種關鍵思想，重心表示法和貪婪支援點選擇來實現。

核心優勢 (AAA Strengths)

1. 數值穩健性與良好條件數：採用重心表示法 (barycentric form) 更優良的條件數 (well-conditioned)，避開浮點數運算中常見的指數不穩定性。
2. 抗虛假極點能力 (Froissart Doublets)：演算法的設計讓結果通常極少或沒有數值虛假極點，如果出現虛假極點，也可以通過最小平方法步驟 (cleanup) 移除。
3. 普適性與靈活性：AAA 演算法的特性在它不受特定逼近域的限制 (interval, a circle, a disk, or a point) 的限制，能有效處理可能包含非連通區域、形狀不規則或 possibly unbounded 的離散點集。
4. 處理奇異點的能力：演算法能夠有效運作，即使被逼近的函數的極點位於採樣點集之中。
5. 高效且實用：演算法速度快且具備靈活性，不用使用者輸入參數，核心複雜度為 $O(Mm^3)$ 次浮點運算，在大多數應用中因為逼近次數 m 較小，計算量是適中的。
6. 收斂特性：演算法有內在的穩定性，因為線性化殘差範數 $\sigma_{min}(A^{(m)})$ 是一個不遞增的函數。

有效條件與假設

1. 目標函數特性：AAA 在需要 Compact Representations 或 Extrapolation 的應用中表現出色，像當函數具有極點或其他奇異點時，對於單位圓盤上的解析函數，有理逼近比多項式逼近更有效。

2. 數據充足：演算法需要一個有限的採樣點集 Z ，並假設函數 $f(z)$ 在 Z 上有定義，每次迭代中，用於最小平方法的剩餘點集 $Z^{(m)}$ 必須至少包含 m 個點，即 $m \leq M/2$ 。
3. 終止條件：演算法預設在相對誤差至 10^{-13} 時終止。

限制與潛在失敗模式

儘管 AAA 演算法具有高穩健性，但還是存在一些限制和可能導致失敗或計算成本提高的情況：

1. 數學與數值限制：
 - i.非最優性：AAA 演算法不尋求在任何特定範數（如 L^2 或 L^∞ 均勻範數）下實現最優逼近，對於需要達到 L^∞ 最優（Minimax）的逼近問題，需要使用更專業的方法或 AAA 的變體。
 - ii.收斂過度：如果收斂容忍度設置得過低，演算法會產生並積累大量的數值虛假極點。
 - iii.大型問題的計算成本：演算法的複雜度為 $O(Mm^3)$ ，對於採樣點數 M 很大，或者逼近階數 m 必須很高才能收斂的問題計算可能變慢。
2. 數據與函數依賴限制：
 - i.對稱性破壞：核心 AAA 演算法通常會破壞函數的固有對稱性，可能會導致在實數區間逼近實函數時產生不希望出現的極點。
 - ii.域內外一致性問題：對於有極點的函數，即使在閉合曲線上實現了高精度逼近，也不能保證結果在曲線包圍的整個區域內精確，除非逼近式具備足夠的極點數量來捕捉原函數的極點。

可能的改進或擴展建議

作者提出了多種 AAA 演算法的變體或擴展，以解決上述限制並擴大應用範圍

1. 解決數值和收斂問題
 - i. L^∞ 最優逼近（Minimax）：建議使用迭代重加權（iterative reweighting*）的非插值（non-interpolatory）AAA 變體，這是 Lawson 演算法的基礎，能夠將最大誤差降至更接近 Minimax 值。
 - ii.對稱性強制：對於偶函數或奇函數的逼近，可以考慮將變數從 z 轉換為 $z^{1/2}$ ，對於一般的對稱性，可以修改演算法，成對選擇支援點來保持對稱性。
 - iii.處理大小數據對稱性：為了在 Riemann 球面上處理 $f(z)$ 值非常大或為 ∞

的點，可以修改線性最小平方法問題，在 $|f(z)| > 1$ 的點處，將矩陣 A 對應的行除以 $f(z)$ ，以保持對大值和小值的對稱性。

2. 擴展逼近類型和範疇

- i.非 $(m - 1, m - 1)$ 類型逼近：考慮類型為 (μ, ν) 且 $\mu \neq \nu$ 的有理逼近，需要限制權重向量 $\{w_j\}$ 位於特定子空間以滿足分子和分母的次數限制。
- ii.非插值逼近：引入獨立的參數 $\{\alpha_j\}$ 和 $\{\beta_j\}$ 來控制分子和分母，使有理逼近式不必在支援點處插值數據，這在與迭代重加權結合以實現最優逼近時特別有用。
- iii.連續採樣點集：將 AAA 演算法直接應用於連續集合 Z ，此時 Loewner 和 Cauchy 矩陣變成準矩陣（quasimatrices），需要在每一步解決連續最佳化問題。
- iv.附帶導數條件 (Hermite-AAA)：透過修改 Cauchy 矩陣 C 的列並增加 Loewner 矩陣 $A^{(m)}$ 的行，可以將逼近擴展到匹配導數數據。
- v.向量和矩陣逼近：將此方法擴展到處理向量或矩陣函數 f 和變數 w 的情境